

09 · 数据集设计

2026-07-31

Contents

09 · 数据集设计	1
1. 设计目标	2
2. 数据类型与格式	2
3. 标注格式 (COCO-like 扩展)	2
4. 程序化合成引擎	2
4.1 引擎架构	3
4.2 题型模板	3
4.3 参数采样	3
4.4 构造器 (Geometry Constructor)	3
4.5 渲染器	3
4.6 规模	3
5. 风格增强	3
6. 真题标注流程	4
6.1 流程	4
6.2 标注工具	4
6.3 规模	4
7. 定理库构建	4
7.1 来源	4
7.2 结构化	4
7.3 向量化	5
8. 数据质量评估	5
8.1 合成数据质量	5
8.2 真题标注质量	5
8.3 评估集划分	5
9. 数据集统计与监控	5
10. 设计路线小结	5

09 · 数据集设计

本文档阐述数据集的类型与格式、标注 Schema、程序化合成引擎、风格增强、真题标注流程与数据质量评估。
数据是”无后训练”范式下的关键杠杆。

1. 设计目标

在无法大规模后训练的约束下，数据的作用转变为：1. 训练轻量检测器（标注符号 YOLO、可选关键点网络）。2. 评估各模块准确率（有 ground truth）。3. 构建 Few-shot 示例库与定理库。4. 回归测试防回退。

故数据集设计遵循**低成本、程序化为主、人工为辅**原则。

2. 数据类型与格式

数据集	内容	格式	用途
GeoImage	几何图片（合成 + 真实）	PNG + JSON 标注	检测器训练/评估
GeoGraph	Geometry Graph 标注	JSON	Graph 构建、关系抽取评估
GeoDSL	DSL 标注	YAML	LLM Prompt、Few-shot
GeoProof	证明步骤	JSON (step+reason)	推理评估、SFT（可选小量）
TheoDB	几何定理库	结构化条目	RAG 检索

3. 标注格式（COCO-like 扩展）


```
{
  "image": "synth_000123.png",
  "size": [400, 320],
  "objects": [
    {"type": "Point", "label": "A", "coords": [180, 84]},
    {"type": "Circle", "label": "O", "center": [180, 160], "radius": 75.5},
    {"type": "Segment", "label": "AB", "endpoints": [[180, 84], [260, 140]]}
  ],
  "relations": [
    {"rel": "On", "src": "A", "dst": "O"},
    {"rel": "Tangent", "src": "AB", "dst": "O", "at": "A"},
    {"rel": "Perpendicular", "src": "OA", "dst": "AB"}
  ],
  "dsl": "< 对应 DSL>",
  "proof": [
    {"step": 1, "statement": "...", "reason": "..."}
  ],
  "answer": "AB · AC = AD · AE",
  "problem_text": "如图，AB 切圆 O 于 A..."
}
```

标注格式与 Geometry Graph/DSL 双向兼容，一套标注支持多模块评估。

4. 程序化合成引擎

合成是数据的主要来源，零标注成本、可无限生成。

4.1 引擎架构



4.2 题型模板

按几何对象分类模板：- triangle_basic: 随机三角形 + 角度/长度标注。- circle_tangent: 随机圆 + 切线 + 切点。- circle_inscribed_angle: 圆上多点 + 圆周角。- ellipse_focus: 椭圆 + 焦点 + 椭圆上点。- similar_triangle: 相似三角形构图。- two_circles: 两圆关系（外切/相交/...）。

每个模板定义：参数空间、构图规则、自动生成 GT（Graph/DSL/Proof）。

4.3 参数采样

- 坐标在画布范围内均匀采样。
- 角度/长度约束满足几何有效性（如三角形两边之和 > 第三边）。
- 标签按 A,B,C,... 顺序分配。
- 随机决定是否添加标注符号（角标/等长/平行）。

4.4 构造器（Geometry Constructor）

根据模板与参数，构造几何对象并**自动推导**全部关系（用解析几何），生成：- PrimitiveSet（GT）- GeometryGraph（GT，所有关系 verified=true）- DSL - Proof（若模板含证明模板，填充具体数值）

4.5 渲染器

- matplotlib + cairo 渲染为 PNG，线宽/字体可控。
- 模拟试卷风格：白底黑线、标签字体、标注符号。
- 输出原图 + GT 标注 JSON。

4.6 规模

可无限生成，目标：| 数据集 | 量级 | | - | - | | GeoImage (合成) | 100k+ | | GeoProof (合成) | 10k |

5. 风格增强

合成图与真实试卷存在域差距，需风格增强提升泛化：

增强	方法	目的
高斯噪声	叠加随机噪声	模拟低质量扫描
抖动	线段像素随机偏移	模拟手绘抖动
倾斜	随机旋转 $\pm 5^\circ$	模拟拍摄倾斜
光照不均	叠加渐变	模拟光照
手绘风格迁移	GAN/风格迁移或简化笔触模拟	模拟手绘图
字体变化	多种字体渲染标签	模拟不同试卷
模糊	高斯模糊	模拟失焦

增强后重新生成 GT（保持几何关系不变，仅像素变化）。

6. 真题标注流程

合成数据无法完全覆盖真实试卷的多样性，需少量真题精标。

6.1 流程

1. **收集**：从中高考真题、教辅收集 500~1000 张几何图。
2. **VLM 预标注**：用 VLM (Qwen-VL/GPT-4V) 预标注对象与关系，降低人工成本。
3. **人工校正**：标注员校正预标注，确保 GT 准确。
4. **交叉校验**：双人标注 + 仲裁，保证质量。
5. **入库**：作为评估集 (hold-out) 与微调小模型用。

6.2 标注工具

自研轻量 Web 标注工具（基于 LabelMe 扩展），支持：- 点/线/圆/椭圆绘制。- 关系标注（连线 + 关系类型）。- 标签关联。
- 自动导出标准 JSON。

6.3 规模

数据集	量级
GeoImage (真实)	1k~2k
GeoProof (真题)	1k

7. 定理库构建

7.1 来源

从教材（人教版初高中）、题库整理 200~500 条几何定理。

7.2 结构化

每条定理 (id, name, premise, conclusion, condition, category, reference)（见 08-Solver § 3）。

7.3 向量化

按 name + premise + conclusion 向量化，存入 FAISS/Chroma，供 RAG 检索。

8. 数据质量评估

8.1 合成数据质量

- **几何有效性**：自动校验合成图关系自洽（如三角形不等式）。
- **渲染正确性**：抽样人工检查图像与 GT 一致。
- **多样性**：统计参数分布，避免模式单一。

8.2 真题标注质量

- **双人一致率** (Cohen's κ)：目标 > 0.85 。
- **仲裁机制**：不一致项第三人仲裁。
- **抽样复审**：10% 抽样复审。

8.3 评估集划分

- 合成数据：训练/验证。
 - 真题数据：评估 (hold-out, 绝不参与训练/微调)，反映真实泛化能力。
-

9. 数据集统计与监控

指标	说明
题型分布	各题型样本数，避免偏斜
对象频率	Point/Line/Circle/Ellipse 出现频率
关系频率	各关系类型频率
难度分布	简单/中/难比例
标注一致率	κ 系数

数据集版本化 (DVC 或 git-lfs)，每次迭代记录变更。

10. 设计路线小结

数据集设计路线为：“统一标注 Schema → 程序化合成引擎 (模板 + 参数 + 构造器 + 渲染器) → 风格增强 (缩小域差距) → 真题小量精标 (VLM 预标注 + 人工校正) → 定理库结构化 → 质量评估 (一致率/分布) → 评估集 hold-out”。以零成本合成为主、真题精标为辅，在无后训练约束下为各模块提供训练与评估支撑。